

$$R_{tr}(\hat{\beta}) = \frac{1}{N} \sum_{i=1}^N (y_i - \beta^T x_i)^2 \quad (1)$$

$$R_{te}(\hat{\beta}) = \frac{1}{M} \sum_{i=1}^M (\bar{y}_i - \beta^T \bar{x}_i)^2$$

اگر $N \ll M$ باشد:

$$E[R_{te}(\hat{\beta})] = \frac{1}{M} \sum_{i=1}^M E(\bar{y}_i - \hat{\beta}^T \bar{x}_i)^2$$

$$\geq \frac{1}{M} \sum_{i=1}^M E(\bar{y}_i - \bar{\beta}^T \bar{x}_i)^2$$

$\bar{\beta}$ پارامتری است که expected را روی داده‌های تست کمینه می‌کند.

$$= E(\bar{y}_1 - \bar{\beta}^T \bar{x}_1)^2$$

$$= \frac{1}{N} \sum_{i=1}^N E(\bar{y}_i - \bar{\beta}^T \bar{x}_i)^2$$

اگر داده‌ها iid باشند

$$\geq \frac{1}{N} \sum_{i=1}^N E(\bar{y}_i - \beta'^T \bar{x}_i)^2$$

β' پارامتری است که expected را روی N داده تست کمینه می‌کند.

$$= \frac{1}{N} \sum_{i=1}^N E(y_i - \hat{\beta}^T x_i)^2$$

expected روی داده‌های train نیز همان مقدار است

$$= E[R_{tr}(\hat{\beta})]$$

اگر داده‌های train و تست طبق گفته صورت سوال iid باشند.

$$\Rightarrow E[R_{te}(\hat{\beta})] \geq E[R_{tr}(\hat{\beta})]$$

اگر $N > M$ باشد :

$$E[R_{tr}(\hat{\beta})] = \frac{1}{N} \sum_{i=1}^N E(y_i - \hat{\beta}^T x_i)^2$$

$$= E(y_1 - \hat{\beta}^T x_1)^2 \rightarrow \text{اگر داده‌ها iid باشند}$$

$$= \frac{1}{M} \sum_{i=1}^M E(y_i - \hat{\beta}^T x_i)^2$$

$$\leq \frac{1}{M} \sum_{i=1}^M E(y_i - \beta'^T x_i)^2$$

β' پدامتری که روی expected, روی داده‌های ست همیشه می‌کند.

$$= \frac{1}{M} \sum_{i=1}^M E(\bar{y}_i - \bar{\beta}^T \bar{x}_i)^2$$

\rightarrow iid بودن داده‌های train نسبت به test

$$\leq \frac{1}{M} \sum_{i=1}^M E(\bar{y}_i - \hat{\beta}^T \bar{x}_i)^2$$

$$= E[R_{te}(\hat{\beta})]$$

$$\Rightarrow E[R_{tr}(\hat{\beta})] \leq E[R_{te}(\hat{\beta})]$$

② هفتی با مدتی سه‌باری

$$J_{\lambda}(w) = \frac{1}{2} \|y - Xw\|_2^2 + \lambda \|w\|_1 \quad (\text{الف})$$

$$J_{\lambda}(w) = \frac{1}{2} \sum_{j=1}^d (y_j - X_{:,j} w)^2 + \lambda \sum_{j=1}^d |w_j|$$

$$J_{\lambda}(w) = \frac{1}{2} (y - Xw)^T (y - Xw) + \lambda \|w\|_1$$

$$J_{\lambda}(w) = \frac{1}{2} y^T y - w^T X^T y + \frac{1}{2} w^T X^T X w + \lambda \|w\|_1 \quad \Rightarrow \quad X^T X = I$$

$$J_{\lambda}(w) = \frac{1}{2} \|y\|_2^2 - w^T X^T y + \frac{1}{2} w^T W + \lambda \|w\|_1$$

$$J_{\lambda}(w) = g(y) + \sum_{j=1}^d -w_j^T X_{j,:}^T y + \frac{1}{2} w_j^T w_j + \lambda |w_j|$$

$$J_{\lambda}(w) = g(y) + \sum_{j=1}^d \phi(X_{j,:}^T y; w_j; \lambda)$$

در تابع ϕ ، مشخص است بهینه‌سازی w_j^* تحت تأثیر ویژگی نام مثل و خروجی داده وابسته است.
(ب) اگر $w_i \geq 0$ باشد آنوقت w_i

$$\frac{\partial}{\partial w_i} \left(-w_i^T X_{i,:}^T y + \frac{1}{2} w_i^T w_i + \lambda |w_i| \right) = 0$$

$$\begin{aligned} w_i &\geq 0 \\ \Rightarrow -X_{i,:}^T y + w_i + \lambda &= 0 \Rightarrow w_i = X_{i,:}^T y - \lambda \end{aligned}$$

(ب) اگر $w_i < 0$ باشد، آنگاه w_i

$$\frac{\partial}{\partial w_i} \left(-w_i^T X_{i,:}^T y + \frac{1}{2} w_i^T w_i + \lambda |w_i| \right) = 0$$

$$w_i < 0 \Rightarrow -X_{i,:}^T y + w_i - \lambda = 0 \Rightarrow w_i = X_{i,:}^T y + \lambda$$

$$w_i = X_{i,:}^T y - \lambda = 0 \Rightarrow X_{i,:}^T y = \lambda$$

(ت)

زمانی w_i صفر خواهد شد که تأثیر ویژگی i ام برای تشخیص y ناچیز باشد.
 یا ممکن است ویژگی i ام دارای Correlation بالایی با بقیه ویژگی‌ها باشد
 و برای ساده سازی و جلوگیری از overfitting مدل، از آن صرف نظر
 شده است.

$$J_{\lambda}(w) = \frac{1}{2} \|y - Xw\|_2^2 + \frac{1}{2} \lambda \|w\|_2^2 \quad (ث)$$

$$J_{\lambda}(w) = \frac{1}{2} \|y\|_2^2 - w^T X^T y + \frac{1}{2} w^T w + \frac{1}{2} \lambda w^T w$$

$$J_{\lambda}(w) = g(y) + \sum_{j=1}^d -w_j^T X_{j,:}^T y + \frac{1}{2} w_j^T w_j + \frac{1}{2} \lambda w_j^T w_j$$

$$\frac{\partial}{\partial w_i} \left(-w_j^T X_{j,:}^T y + \frac{1}{2} w_j^T w_j + \frac{1}{2} \lambda w_j^T w_j \right) = 0$$

$$\Rightarrow -X_{j,:}^T y + w_j + \lambda w_j = 0 \Rightarrow w_j = \frac{X_{j,:}^T y}{1 + \lambda}$$

زمانی که $X_{j,:}^T y = 0$ شود، آنگاه $w_j = 0$ خواهد بود.

③ اگر به‌طور دستی وزن پرسپترون که به شکل زیر است را در نقطه بلیسیم :

$$x^{(i)} \text{ misclassified} \quad w^{(t+1)} = w^{(t)} + \eta \alpha^{(i)} y^{(i)}$$

اگر $w^{(0)} = 0$ در نقطه بلیسیم :

$$w^{(t+1)} = \eta \sum_{i=1}^N K_i \alpha^{(i)} y^{(i)} \quad (\text{به ازای } N \text{ سمپل})$$

* K_i تعداد باری است که سمپل $x^{(i)}$ اشتباه طبقه بندی شده است.

بطور مثال اگر در بار اول، سمپل $x^{(2)}$ اشتباه کلاس بندی شود

$$w^{(1)} = w^{(0)} + \alpha^{(2)} y^{(2)} = \begin{cases} w^{(1)} = w^{(0)} - \alpha^{(2)} & \text{if } y^{(2)} = -1 \\ w^{(1)} = w^{(0)} + \alpha^{(2)} & \text{if } y^{(2)} = +1 \end{cases}$$

اگر بخواهیم به شکل دیگر نمایش دهیم :

$$w = \eta \sum_{i=1}^N K_i \alpha^{(i)} y^{(i)} = \eta \left[\sum_{y^{(i)}=1} K_i \alpha^{(i)} - \sum_{y^{(i)}=-1} K_i \alpha^{(i)} \right]$$

پس اگر $w = \sum_{i=1}^N \alpha_i x^{(i)}$ باشد، آنگاه ضرایب α_i به شکل زیر خواهد بود :

$$\alpha_i = \eta K_i y^{(i)}$$

K_i : تعداد بار اشتباه کلاس بندی شدن داده نام

η : learning rate

$y^{(i)}$: کلاس درست داده نام

$$P(y=1|x) = \frac{P(x|y=1) P(y=1)}{P(x)} \quad \text{naive bayes} \quad (4) \text{ الف}$$

$$P(y=1|x) = \frac{\prod_{i=1}^d P(w_i|y=1)^{c_i} \cdot P(y=1)}{P(x)}$$

$P(w_i|y=1)$
 احتمال حضور word i در یک رایگمنت به شرط کلاس 1

ب) مدل تصمیم گیری مطابق رویه زیر تعریف می شود:

$$P(y=0|x) = P(y=1|x) \Rightarrow \frac{P(y=1|x)}{P(y=0|x)} = 1$$

$$\frac{\prod_{i=1}^d P(w_i|y=1)^{c_i} \cdot P(y=1)}{\prod_{i=1}^d P(w_i|y=0)^{c_i} \cdot P(y=0)} = 1 \quad \rightarrow$$

$$\prod_{i=1}^d \left(\frac{P(w_i|y=1)}{P(w_i|y=0)} \right)^{c_i} \cdot \frac{P(y=1)}{P(y=0)} = 1 \quad \xrightarrow{\log}$$

$$\sum_{i=1}^d c_i \log \frac{P(w_i|y=1)}{P(w_i|y=0)} + \log \frac{P(y=1)}{P(y=0)} = 0$$

اگر c_i را همان ورودی x_i در نظر بگیریم و همچنین مقدار ثابت $b = \log \frac{P(y=1)}{P(y=0)}$ باشد آنگاه:

$$\sum_{i=1}^d x_i w_i + b = 0 \Rightarrow \boxed{w^T x + b = 0}$$

پس مدل تصمیم خطی خواهد بود.

④ (2) از بخش قبل رابطه زیر را برای naive bayes داریم:

$$\log \frac{P(y=1|x)}{P(y=0|x)} = \sum_{i=1}^d C_i \log \frac{P(w_i|y=1)}{P(w_i|y=0)} + \log \frac{P(y=1)}{P(y=0)}$$

$$* \quad P(y=0|x) = 1 - P(y=1|x), \quad P(y=0) = 1 - P(y=1)$$

$$\log \frac{P(y=1|x)}{1 - P(y=1|x)} = \sum_{i=1}^d C_i \log \frac{P(w_i|y=1)}{P(w_i|y=0)} + \log \frac{P(y=1)}{1 - P(y=1)}$$

$$\xrightarrow{\exp} \frac{P(y=1|x)}{1 - P(y=1|x)} = e^{\sum_{i=1}^d C_i \log \frac{P(w_i|y=1)}{P(w_i|y=0)}} \times \frac{P(y=1)}{1 - P(y=1)}$$

$$P(y=1|x) = \frac{e^{\sum_{i=1}^d C_i \log \frac{P(w_i|y=1)}{P(w_i|y=0)}} \times \frac{P(y=1)}{1 - P(y=1)}}{1 + e^{\sum_{i=1}^d C_i \log \frac{P(w_i|y=1)}{P(w_i|y=0)}} \times \frac{P(y=1)}{1 - P(y=1)}}$$

$$\Rightarrow P(y=1|x) = \frac{1}{\frac{1 - P(y=1)}{P(y=1)} \times e^{-\sum_{i=1}^d C_i \log \frac{P(w_i|y=1)}{P(w_i|y=0)}} + 1}$$

$$\Rightarrow P(y=1|x) = \frac{1}{1 + e^{-\log \frac{P(y=1)}{1 - P(y=1)}} e^{-\sum_{i=1}^d C_i \log \frac{P(w_i|y=1)}{P(w_i|y=0)}}}$$

$$\Rightarrow P(y=1|x) = \frac{1}{1 + e^{-\left(\sum_{i=1}^d x_i \log \frac{P(w_i|y=1)}{P(w_i|y=0)} + \log \frac{P(y=1)}{1-P(y=1)}\right)}}$$

$$\Rightarrow P(y=1|x) = \frac{1}{1 + e^{-\left(\sum_{i=1}^d x_i \theta_i + \theta_0\right)}} = \frac{1}{1 + e^{-(\theta^T x + \theta_0)}}$$

(5)

$$P(x|w_1) = N(0, I)$$

$$P(x|w_2) = N([1 \ 1]^T, I)$$

$$P(x|w_3) = \frac{1}{2} N([0.5 \ 0.5]^T, I) + \frac{1}{2} N([-0.5 \ 0.5]^T, I)$$

$$P(w_1) = P(w_2) = P(w_3)$$

الف) احتمال posterior برای $x = [0.3 \ 0.3]^T$

$$P(x|w_1) = \frac{1}{2\pi} e^{-\frac{1}{2} [0.3 \ 0.3] \begin{bmatrix} 0.3 \\ 0.3 \end{bmatrix}} = 0.1455$$

$$P(x|w_2) = \frac{1}{2\pi} e^{-\frac{1}{2} [-0.7 \ -0.7] \begin{bmatrix} -0.7 \\ -0.7 \end{bmatrix}} = 0.0975$$

$$P(x|w_3) = \frac{1}{4\pi} e^{-\frac{1}{2} [-0.2 \ -0.2] \begin{bmatrix} -0.2 \\ -0.2 \end{bmatrix}} + \frac{1}{4\pi} e^{-\frac{1}{2} [0.8 \ -0.2] \begin{bmatrix} 0.8 \\ -0.2 \end{bmatrix}} = 0.1331$$

$$P(w_i|x) \propto P(x|w_i) P(w_i)$$

از آنجایی که $P(w_1) = P(w_2) = P(w_3)$ است پس:

$$P(w_i|x) \propto P(x|w_i)$$

پس چون احتمال $P(x|w_1)$ بیشتر از همه است، پس x متعلق به کلاس 1 می شود.

$$P(w_i | x_2) = \frac{\int P(x_1, x_2 | w_i) P(w_i) dx_1}{P(x_2)} \quad \mu = \begin{bmatrix} * & 0.3 \end{bmatrix}^T \quad \begin{matrix} x_1 & x_2 \end{matrix} \quad (ب)$$

$$P(w_i | x_2) \propto \int P(x_1, x_2 | w_i) \overset{\text{مستقل}}{P(w_i)} dx_1$$

چون $P(w_i)$ ها برابر است :

$$P(w_i | x_2) \propto \int P(x_1, x_2 | w_i) dx_1$$

$$\int P(x_1, x_2 | w_1) dx_1 = \frac{1}{2\pi} \int e^{-\frac{1}{2}(x_1^2 + 0.09)} dx_1$$

$$= \frac{1}{2\pi} e^{\left(\frac{-0.09}{2}\right)} \int e^{-\frac{1}{2}x_1^2} dx_1 =$$

recall that: (integral of gaussian func.)

$$\int_{-\infty}^{+\infty} e^{-a(x+b)^2} dx = \sqrt{\frac{\pi}{a}}$$

$$\int P(x_1, x_2 | w_1) dx_1 = \frac{1}{2\pi} e^{\left(\frac{-0.09}{2}\right)} \sqrt{2\pi} = 0.3813$$

$$\int P(x_1, x_2 | w_2) dx_1 = \frac{1}{2\pi} \int e^{-\frac{1}{2}((x_1-1)^2 + 0.49)} dx_1$$

$$= \frac{1}{2\pi} e^{\left(\frac{-0.49}{2}\right)} \sqrt{2\pi} = 0.3122$$

$$\begin{aligned}
 \int p(x_1, x_2 | w_3) dx_1 &= \frac{1}{4\pi} \int e^{-\frac{1}{2}((x_1 - 0.5)^2 + 0.04)} dx_1 \\
 &+ \frac{1}{4\pi} \int e^{-\frac{1}{2}((x_1 + 0.5)^2 + 0.04)} dx_1 \\
 &= \frac{1}{4\pi} e^{\frac{(-0.04)}{2}} \cdot \sqrt{2\pi} + \frac{1}{4\pi} e^{\frac{(-0.04)}{2}} \sqrt{2\pi} \\
 &= 0.391
 \end{aligned}$$

در نتیجه احتمال کلاس 3 بیشتر از بقیه شد پس $x = [x \ 0.3]^T$ مربوط به کلاس 3 است.

$$J(\theta) = (X\theta - y)^T W (X\theta - y) \quad (6) \quad (7)$$

اگر ماتریس W را شکلی فرض کنیم که عناصر روی قطر اصلی آن $W_{ii} = \frac{1}{2} w^{(i)}$ باشند و بقیه عناصر نیز صفر باشند. همچنین $Z = X\theta - y$ باشد:

$$Z_i = \theta^T x^{(i)} - y^{(i)}, \quad W = \begin{bmatrix} \frac{1}{2} w^{(1)} & 0 & 0 & \dots & 0 \\ 0 & \frac{1}{2} w^{(2)} & & & \\ 0 & & & & \\ \vdots & & & & \\ 0 & 0 & 0 & \dots & \frac{1}{2} w^{(m)} \end{bmatrix} : \text{و } w^{(i)}$$

$$(X\theta - y)^T W (X\theta - y) = Z^T W Z = \frac{1}{2} \sum_{i=1}^m w^{(i)} z_i^2$$

$$= \frac{1}{2} \sum_{i=1}^m w^{(i)} (\theta^T x^{(i)} - y^{(i)})^2 = J(\theta)$$

$$\nabla_{\theta} J(\theta) = \nabla_{\theta} (\theta^T X^T W X \theta - 2 y^T W X \theta + y^T W y) \quad (6)$$

$$= 2 X^T W X \theta - 2 X^T W y$$

$$\nabla_{\theta} J(\theta) = 0 \Rightarrow 2 X^T W X \theta = 2 X^T W y$$

$$\Rightarrow X^T W X \theta = X^T W y$$

$$\Rightarrow \theta = (X^T W X)^{-1} X^T W y$$

$$ML(\theta) = \arg \max_{\theta} \prod_{i=1}^m p(y^{(i)} | x^{(i)}; \theta) \quad (7)$$

$$= \arg \max_{\theta} \sum_{i=1}^m \log p(y^{(i)} | x^{(i)}; \theta)$$

$$= \arg \max_{\theta} \sum_{i=1}^m \left(\log \frac{1}{\sqrt{2\pi} \sigma^{(i)}} - \frac{(y^{(i)} - \theta^T x^{(i)})^2}{2 \sigma^{(i)2}} \right)$$

$$= \arg \max_{\theta} \sum_{i=1}^m \left(- \frac{(y^{(i)} - \theta^T x^{(i)})^2}{2 \sigma^{(i)2}} \right) \leq 0 \quad \text{negative or zero}$$

$$= \arg \min_{\theta} \sum_{i=1}^m \frac{1}{2 \sigma^{(i)2}} (y^{(i)} - \theta^T x^{(i)})^2$$

linear regression

$$= \arg \min_{\theta} \frac{1}{2} \sum_{i=1}^m \underbrace{\frac{1}{\sigma^{(i)2}}}_{w^{(i)}} (y^{(i)} - \theta^T x^{(i)})^2 \Rightarrow w^{(i)} = \frac{1}{\sigma^{(i)2}}$$

$$X = [X_1, X_2]^T \text{ فـ } \bar{0}2, \quad \left. \begin{matrix} c=0 \\ c=1 \\ c=2 \end{matrix} \right\} \text{ سـ } \bar{0}2$$

$$P(x_1 | y=0) = \text{Ber}(x_1, 0.5) = 0.5^{x_1} 0.5^{1-x_1} = 0.5$$

$$P(x_1 | y=1) = 0.5, \quad P(x_1 | y=2) = 0.5$$

$$P(x_2 | y=0) = \text{Normal}(x_2, -1, 1) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(x_2+1)^2}{2}}$$

$$P(x_2 | y=1) = \text{Normal}(x_2, 0, 1) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x_2^2}{2}}$$

$$P(x_2 | y=2) = \text{Normal}(x_2, 1, 1) = \frac{1}{\sqrt{2\pi}} e^{-\frac{(x_2-1)^2}{2}}$$

الف) $P(y | x_1=0, x_2=0)$

$$\text{فـ } X = [x_1, x_2]^T$$

Bayes theorem: $P(y=c | X) = \frac{P(X | y=c) P(y=c)}{P(X)}$

ind. var
 $\Rightarrow P(y=c | X) = \frac{\prod_{i=1}^n P(x_i | y=c) \cdot P(y=c)}{P(X)}$

Total probability:

$$P(X) = \sum_{c \in C} P(X | y=c) P(y=c)$$

$$P(X) = P(X|y=0) P(y=0) + P(X|y=1) P(y=1) + P(X|y=2) P(y=2)$$

$$P(X|y=0) = P(x_1|y=0) P(x_2|y=0) = 0.5 \times \frac{1}{\sqrt{2\pi}} e^{-\frac{(x_2+1)^2}{2}}$$

$$\textcircled{*} X = [x_1=0 \quad x_2=0]^T$$

$$P(X|y=0) = 0.5 \times \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}}$$

$$P(X|y=1) = P(x_1|y=1) P(x_2|y=1) = 0.5 \times \frac{1}{\sqrt{2\pi}} e^{-\frac{x_2^2}{2}}$$

$$P(X|y=1) = 0.5 \times \frac{1}{\sqrt{2\pi}} e^0 = \frac{1}{2\sqrt{2\pi}}$$

$$P(X|y=2) = P(x_1|y=2) P(x_2|y=2) = 0.5 \times \frac{1}{\sqrt{2\pi}} e^{-\frac{(x_2-1)^2}{2}}$$

$$P(X|y=2) = 0.5 \times \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}}$$

$$\Rightarrow P(X) = \frac{1}{4\sqrt{2\pi}e} + \frac{1}{8\sqrt{2\pi}} + \frac{1}{8\sqrt{2\pi}e}$$

$$P(X) = \frac{3}{8\sqrt{2\pi}e} + \frac{1}{8\sqrt{2\pi}} = \frac{3e^{-\frac{1}{2}} + 1}{8\sqrt{2\pi}}$$

$$\text{الف) } P(y=0|x) = \frac{P(x|y=0) \cdot P(y=0)}{P(x)} =$$

$$\Rightarrow P(y=0|x) = \frac{\frac{e^{-\frac{1}{2}}}{4\sqrt{2\pi}}}{\frac{3e^{-\frac{1}{2}} + 1}{8\sqrt{2\pi}}} = \frac{2e^{-\frac{1}{2}}}{3e^{-\frac{1}{2}} + 1}$$

$$P(y=1|x) = \frac{\frac{1}{8\sqrt{2\pi}}}{\frac{3e^{-\frac{1}{2}} + 1}{8\sqrt{2\pi}}} = \frac{1}{3e^{-\frac{1}{2}} + 1}$$

$$P(y=2|x) = \frac{\frac{e^{-\frac{1}{2}}}{8\sqrt{2\pi}}}{\frac{3e^{-\frac{1}{2}} + 1}{8\sqrt{2\pi}}} = \frac{e^{-\frac{1}{2}}}{3e^{-\frac{1}{2}} + 1}$$

$$P_{Y|X_1, X_2} = \begin{bmatrix} \frac{2e^{-\frac{1}{2}}}{3e^{-\frac{1}{2}} + 1} \\ \frac{1}{3e^{-\frac{1}{2}} + 1} \\ \frac{e^{-\frac{1}{2}}}{3e^{-\frac{1}{2}} + 1} \end{bmatrix}$$

$$c) P(y|x_1=0)$$

$$P(y=0 | x_1=0) = \frac{P(x_1=0 | y=0) P(y=0)}{P(x_1=0)}$$

$$P(y=1 | x_1=0) = \frac{P(x_1=0 | y=1) P(y=1)}{P(x_1=0)}$$

$$P(y=2 | x_1=0) = \frac{P(x_1=0 | y=2) P(y=2)}{P(x_1=0)}$$

$$\left\{ \begin{array}{l} P(x_1=0) = \sum_{c \in C} P(x_1=0 | y=c) P(y=c) \\ \quad = 0.5 \times 0.5 + 0.5 \times 0.25 + 0.5 \times 0.25 \\ P(x_1=0) = 0.5 \end{array} \right.$$

$$P(y=0 | x_1=0) = \frac{0.5 \times 0.5}{0.5} = 0.5$$

$$P(y=1 | x_1=0) = \frac{0.5 \times 0.25}{0.5} = 0.25$$

$$P(y=2 | x_1=0) = \frac{0.5 \times 0.25}{0.5} = 0.25$$

$$P_{Y|X_1} = \begin{bmatrix} 0.5 \\ 0.25 \\ 0.25 \end{bmatrix}$$

$$c) \quad P(y | x_2 = 0)$$

$$P(x_2 = 0 | y = 0) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}}$$

$$P(x_2 = 0 | y = 1) = \frac{1}{\sqrt{2\pi}}$$

$$P(x_2 = 0 | y = 2) = \frac{1}{\sqrt{2\pi}} e^{\frac{1}{2}}$$

$$P(x_2 = 0) = \sum_{c \in C} P(x_2 = 0 | y = c) P(y = c)$$

$$= \frac{e^{-1/2}}{\sqrt{2\pi}} \times 0.5 + \frac{1}{\sqrt{2\pi}} \times 0.25 + \frac{e^{1/2}}{\sqrt{2\pi}} \times 0.25$$

$$P(x_2 = 0) = \frac{0.75 e^{-1/2} + 0.25}{\sqrt{2\pi}}$$

$$P(y = 0 | x_2 = 0) = \frac{\frac{e^{-1/2}}{\sqrt{2\pi}} \times 0.5}{\frac{0.75 e^{-1/2} + 0.25}{\sqrt{2\pi}}} = \frac{0.5 e^{-1/2}}{0.75 e^{-1/2} + 0.25}$$

$$P(y = 1 | x_2 = 0) = \frac{\frac{0.25}{\sqrt{2\pi}}}{\frac{0.75 e^{-1/2} + 0.25}{\sqrt{2\pi}}} = \frac{0.25}{0.75 e^{-1/2} + 0.25}$$

$$P(y = 2 | x_2 = 0) = \frac{\frac{e^{1/2}}{\sqrt{2\pi}} \times 0.25}{\frac{0.75 e^{-1/2} + 0.25}{\sqrt{2\pi}}} = \frac{0.25 e^{1/2}}{0.75 e^{-1/2} + 0.25}$$

ج)

$$P_{Y|X_2} = \begin{bmatrix} \frac{0.5 e^{-1/2}}{0.75 e^{-1/2} + 0.25} \\ \frac{0.25}{0.75 e^{-1/2} + 0.25} \\ \frac{0.25 e^{-1/2}}{0.75 e^{-1/2} + 0.25} \end{bmatrix}$$

ت) متوجه می شویم دو احتمال بخش 'الف' و 'ب' یکسان است:

$$P(Y|\alpha_1=0, \alpha_2=0) = P(Y|\alpha_2=0)$$

این موضوع بدین دلیل است که $P(\alpha_1=0|Y)$ به ازای $Y=c$ یکسان

و برابر با 0.5 است و در بخش الف صرفاً احتمال $P(\alpha_1=0|Y)$ در

صورت و خارج کسر ضرب شده است که با یک فاکتور گرفتن و حذف کردن آن

از صورت و خارج، به احتمال بخش 'ب' می رسم.

$$P(Y|\alpha_1=0, \alpha_2=0) = P(Y|\alpha_2=0)$$

$$\frac{P(\alpha_1=0|Y=c) P(\alpha_2=0|Y=c) P(Y=c)}{P(\alpha_1=0, \alpha_2=0)} = \frac{P(\alpha_2=0|Y=c) P(Y=c)}{P(\alpha_2=0)}$$

Constant مستقل از c

$$\frac{\underbrace{P(\alpha_1=0|Y)}_{\text{Constant}} \times P(\alpha_2=0|Y=c) P(Y=c)}{P(\alpha_1=0|Y) P(\alpha_2=0)} = \frac{P(\alpha_2=0|Y=c) P(Y=c)}{P(\alpha_2=0)}$$